Table des matières

Chapitre 1:Le signal ECG Caractéristiques et système d'acquisition..... 3
1. Introduction :.....3
2. Electrocardiogramme :..... 3
2-1. Dérivations électrocardiographiques :..... 4
2-1-1. Les dérivations bipolaires (Einthoven):..... 5
2-1-2 . Les dérivations unipolaires (Wilson) :..... 5
2-1-3. Les dérivations standards (précordiales) :..... 5
3.Tracé électrique du coeur :.....6
4 . Les paramètres du signal ECG :..... 7
4-1.Ondes Intervalles et Segments:.....7
4-2. fréquence :.....9
4-2-1. Rythme Régulier :..... 9
4-2-2. Rythme Irrégulier :.....9
4-3. Amplitude:..... 9
5 . Acquisition d'un signal ECG :..... 10
6.Conclusion :.....12
Chapitre 2 : Extraction et traitement du signal ECG.....13
1. Introduction :.....13
2.Les types de bruits présents dans l'ECG :..... 14
2-1.Bruits techniques :.....14
2-1-1.Bruit dû au secteur :..... 14
2-1-2. Bruit dû au mauvais contact électrode-peau :.....14
2-1-3.Autres bruits :..... 15
2-1.Bruits Physiques :.....15
2-1-1.Mouvements de la ligne de base :..... 15
2-1-2.Bruit myoélectrique ou tremblement somatique :[5].....16
3.Extraction des paramètres du signal ECG :..... 16
3-1.Prétraitement du signal ECG :..... 17
3-2 Méthodes d'extraction des paramètres du signal ECG :.....19
3-2-1.Méthodes en domaine temporel (Time Domain):.....19
3-2-2.Méthodes en domaine fréquentiel (Frequency Domain) :.....19
3-2-3.Méthode temps-fréquence (Time-Frequency Domain) :..... 20
3-2-4.Méthodes d'intelligence artificielle (IA) :.....20
4. L'extraction par la méthode Pan and Tompkins :.....21
4-1. Les étapes de traitement de la détection du complexe QRS:.....22
4-2 Justification du choix de la méthode d'extraction :..... 26
5.Conclusion :.....26
Chapitre 3: Détection des pathologies cardiaques par machine learning..... 27

1. Introduction.....28
2.Recherche Des Données.....28
3. Outils utilisés.....30
3-1. Google Colab :.....30
3-2 .Python :.....31
3-3. NumPy :.....31
3-4. Matplotlib :.....31
3-5.Wfdb :.....32
3-6.Scipy.signal :.....32
3-7. Scikit-learn :.....33
3-8.NeuroKit2 :.....33
4. Prétraitement des signaux ECG.....33
5. Extraction de Caractéristiques Physiologiques.....34
6. Visualisation des caractéristiques et des classes.....35
7.Apprentissage Automatique.....37
8.Métrique d'évaluation des modèles.....39
8.1. L'exactitude :.....39
8.2. La précision :.....39
8.3 Le rappel :.....39
8.4. F1-score :.....40
8.5. ROC AUC :.....41
9. Les Modèles D'apprentissage.....41
9.1.la regression logistique :.....41
9.1-1.Logit (log-odds) :.....42
9.1-2.Fonction de Coût (Log-Loss) :.....42
9.1-3.Fonction Sigmoïde :.....43
9.2. Random Forest :.....43
9.2-1. Principe de fonctionnement :.....43
9.2-2. Fonction de décision d'un arbre :.....44
9.2-3. Fonction de coût (impureté) :.....44
9.3.XGBoost :.....45
9.3-1.Fonction Objectif :.....46
9.3-2. Optimisation Par Gradient.....47
9.3-3.Régularisation :.....47
9.3-4.Arbres de Décision :.....47
10.Métrique d'évaluation des modèles.....47
10.1. Performance des Modèles :.....47
10.1-1.XGBoost :.....48
10.1-2.Random Forest :.....48
10.1-3.Régression Logistique.....49
10.2 Interprétation des Modèles :.....49
11. Développement d'une Interface.....52
12 .Conclusion.....53

Liste des Figures

Figure 1.1 : Electrocardiogramme…….11

Figure 1.2 : Les 12 dérivations de l'ECG……...13

Figure 1.3 : L'onde électrique d'un battement de cœur …….13

Figure 1.4 : Nomenclature standardisée par l'ECG……15

Figure 2.1 : Bruit du secteur……21

Figure 2.2 : Bruit dû au mauvais contact électrode-peau ……...21

Figure 2.3 : Bruit généré par le mouvement du patient ……..23

Figure 2.4 : Méthodologie d'extraction des paramètres ECG …….27

Figure 2.5 : Caractéristiques d'un battement cardiaque ……..28

Figure 2.6 : Étapes de la méthode Pan and Tompkins…….29

Figure 2.7 : Étapes clés du traitement Pan-Tompkins…….32

Figure 3.1 : Google Colab……37

Figure 3.2 : Python……...38

Figure 3.3 : Numpy……...38

Figure 3.4 : Matplotlib……..39

Figure 3.5 : Scipy.signal……40

Figure 3.6 : Signal ECG nettoyé avec pics R……42

Figure 3.7 : Matrice de corrélation……43

Figure 3.8 : Distribution des classes……..43

Figure 3.9 : Artificial intelligence……44

Figure 3.10 : Les types de l'apprentissage automatique ……...45

Figure 3.11 : Matrice de confusion……...58

Figure 3.12 : Courbe ROC multiclasses……58

Figure 3.13 : Interface de l'application finale……59.

Liste des tableaux

Table 2.1- : Étapes de prétraitement du l'ECG et leurs objectifs……....18

Table 3.1- : Evaluation des performances du modèle XGBoost……..48

Table 3.2- : Evaluation des performances du modèle Random Forest……....49

Table 3.3- : Evaluation des performances du modèle Logistic Regression…….49

Liste des abréviations

ECG : Électrocardiogramme

P : Onde P (dépolarisation auriculaire)

Q:Onde Q (première déflexion négative du complexe QRS)

R: Onde R (déflexion positive principale du QRS)

S:Onde S (déflexion négative suivant l'onde R)

T : Onde T (repolarisation ventriculaire)

U:Onde U (rare, postérieure à T, origine incertaine)

R-R : Intervalle entre deux pics R

PR: Intervalle PR (du début de P au début de QRS)

PQ: Segment PQ (du début de P au début de Q)

QRS: Complexe QRS (dépolarisation ventriculaire)

QT: Intervalle QT (du début de QRS à la fin de T)

ST:Segment ST (fin de S jusqu'au début de T)

RR:Intervalle RR (entre deux ondes R consécutives)

D1:Dérivation I (entre bras droit et bras gauche)

D2:Dérivation II (entre bras droit et jambe gauche)

D3:Dérivation III (entre bras gauche et jambe gauche)

aVR: Augmented Voltage Right arm (vue du bras droit)

aVL: Augmented Voltage Left arm (vue du bras gauche)

aVF: Augmented Voltage Foot (vue de la jambe gauche)

V1 à V6:Dérivations placées sur la poitrine (permettent une vue horizontale du cœur)

DSP: Digital Signal Processing (Traitement Numérique du Signal)

DWT: Discrete Wavelet Transform (Transformée en Ondelettes Discrète)

HPV:*Heart Pulse Variability* (Variabilité du pouls cardiaque)

CNN: Convolutional Neural Network (Réseau de Neurones Convolutif)

DL: Deep Learning (Apprentissage Profond)

ML: Machine Learning (Apprentissage Automatique)

ADC: Analog to Digital Converter (Convertisseur Analogique-Numérique)

PTBDB : PTB Diagnostic ECG Database

GPU : Graphics Processing Unit

IDE :Integrated Development Environment

TPU :Tensor Processing Unit

DEDICATION

Nous dédions ce travail avec une profonde sincérité…

À nos parents,

Qui nous ont portées bien avant que l'on apprenne à marcher seules. Leur amour, leur patience et leur confiance sont les fondations invisibles de tout ce que nous accomplissons aujourd'hui.

À nos familles,

Pour leurs encouragements constants, leur soutien dans les moments de doute, et leur présence silencieuse mais essentielle tout au long de cette aventure.

À nos amis,

Qui ont su nous arracher des sourires au milieu du stress, et qui ont cru en nous même quand nous étions au bord de l'épuisement.

À notre chère école, l'ENSIT,

Pour le cadre de savoir, de rigueur et de curiosité scientifique qu'elle nous a offert, et à tous les enseignants qui ont marqué notre parcours.

Et surtout…

À notre duo, Siwar & Nawel,

Pour cette collaboration sincère, équilibrée, remplie de respect, d'écoute, de partages, de longues heures de travail… et de quelques fous rires entre deux lignes de code.

REMERCIEMENT

Nous souhaitons exprimer notre profonde gratitude à toutes les personnes qui nous ont soutenues tout au long de ce projet de fin d'année.

Tout d'abord, nous tenons à remercier chaleureusement notre encadrante **Madame Mansouri Balkine**, pour sa disponibilité, ses conseils précieux, et son accompagnement tout au long de cette étude. Son expertise et son encadrement ont été essentiels à l'avancement et à la qualité de notre travail.Je souhaite également exprimer ma reconnaissance à **Monsieur Abid Sabeur**, président du jury, pour avoir accepté d'évaluer mon travail.

Nous remercions également l'équipe pédagogique de l'ENSIT, et en particulier le département de Mathématiques, pour les connaissances et les compétences qu'ils nous ont transmises tout au long de notre formation.

Un remerciement spécial à nos familles et nos proches, pour leur soutien moral constant, leur patience et leurs encouragements tout au long de cette aventure.

Enfin, nous tenons à souligner l'excellente collaboration que nous avons eue en tant que binôme. Ce travail a été pour nous une expérience enrichissante à la fois sur le plan académique et humain.

INTRODUCTION GÉNÉRALE

Le cœur est l'organe central du système cardiovasculaire : il peut être affecté de nombreuses pathologies. Avec l'évolution des techniques, les médecins disposent aujourd'hui d'outils performants pour observer le fonctionnement du muscle cardiaque et dresser ainsi leur diagnostic. Parmi les examens cardiologiques possibles, l'électrocardiogramme (ECG) qui est un signal de nature électro-physiologique dont le tracé matérialise l'activité électrique du cœur capté par des électrodes placées à la surface du corps.

Dans le but d'exploiter au mieux les données ECG en grande quantité et dont l'analyse manuelle est difficile, les systèmes intelligents de diagnostic sont apparus. Ces systèmes permettent d'améliorer la qualité du signal (filtrage des bruits), le rehaussement des informations pertinentes, l'extraction des informations qui ne sont pas visibles par une analyse visuelle directe, ainsi que de proposer un diagnostic qui puisse apporter une aide suffisante pour permettre aux médecins non spécialistes ou débutants de prendre les bonnes décisions.

Cependant, l'automatisation de la détection des maladies cardiovasculaires à partir du signal ECG n'est pas triviale, notamment parce qu'il est difficile d'extraire de ce dernier toutes les informations dont se sert le médecin pour faire un bon diagnostic. En outre, fournir à un système suffisamment de connaissances expertes pour automatiser le diagnostic est une tâche extrêmement coûteuse et fastidieuse. Un système de traitement automatisé de l'ECG se compose généralement de quatre étapes successifs comme suit: le prétraitement du signal, la détection des ondes, l'extraction des paramètres pertinents, et enfin la classification/discrimination des anomalies. L'étape de prétraitement (ou filtrage) du signal consiste essentiellement à éliminer les différents types de bruits qui affectent le signal ECG durant son acquisition, La détection a pour but la localisation des différentes ondes de l'ECG ainsi que la mesure de leur durée d'une façon exacte et fiable Les mesures faites sur le signal ECG après la détection peuvent être désigné sous le nom des vecteurs de paramètres

caractéristiques. C’est dans l’étape extraction/sélection que se réalisent ces mesures. L’étape de sélection permet de choisir les paramètres les plus pertinents pour maximiser la divergence entre les classes, tout en maintenant toujours l'information suffisante pour permettre la discrimination.

Dans le cadre de notre projet de fin d’année, nous avons choisi d’explorer cette intersection entre biomédecine et intelligence artificielle, à travers l’étude et l’extraction des paramètres caractéristiques du signal ECG. Notre objectif principal est de comprendre la structure du signal ECG, d'en extraire les informations pertinentes (telles que les ondes P, QRS, T), puis d'exploiter ces paramètres pour identifier des anomalies cardiaques à l’aide de méthodes d’apprentissage automatique.

Ce projet a été réalisé en plusieurs étapes : analyse du signal ECG, mise en œuvre d’algorithmes de détection comme celui de Pan-Tompkins, traitement des données, visualisation, puis classification des pathologies à l’aide de modèles intelligents. Pour cela, nous avons utilisé le dataset open source **PTB Diagnostic ECG Database (PTB-DB),** contenant une large variété d'enregistrements ECG annotés. Enfin nous clôturons notre rapport par une conclusion générale .

Chapitre 1:Le signal ECG Caractéristiques et système d'acquisition

1. Introduction :

Le corps humain est une source de signaux électriques, l'étude de ces signaux donne de riches informations sur l'activité des organes de l'homme. Notamment le Coeur , qui est assimilé à une pompe, dont sa contraction nécessite une impulsion électrique qui le traverse d'un point à l'autre. L'ECG est un test rapide qui permet une étude relativement fine de cette activité électrique, et de déterminer si elle est normale ou anormale. l'objectif de ce chapitre est de présenter d'un côté les bases théoriques nécessaires à la compréhension du signal électrocardiographique ECG. Nous y décrivons son origine physiologique, ses composantes (onde P, complexe QRS, onde T, etc.), ainsi que les principales pathologies qu'il permet de diagnostiquer,ainsi que les paramètres temporels et morphologiques qui le caractérisent.D'un autre côté, ce chapitre introduit le système d'acquisition du signal ECG, en décrivant les dispositifs utilisés .

2. Electrocardiogramme :

L'électrocardiogramme ECG est le signal traduisant l'enregistrement des activités bioélectriques du système cardiaque. Il est riche en informations sur les aspects fonctionnels du cœur et du système cardio-vasculaire [1].

Ce signal électrophysiologique est sous forme d'une série d'ondes électriques,

caractérisées par des formes et des durées particulières, qui se répètent à chaque cycle cardiaque. La fréquence de battement, la nature et la genèse du rythme, l'excitation et ses effets, ainsi que les perturbations éventuelles, que celles-ci soient d'origine anatomique ou mécanique, qu'elles concernent des altérations tissulaires ou des perturbations de la circulation sanguine sont véhiculées par le signal de l'ECG, d'où son extrême importance.

le système d'acquisition est constitué en général de :

- Un ensemble d'électrodes destinées à être appliquées en contacte directe du patient.
- Un système d'amplification des signaux issus des électrodes.
- Un appareil enregistreur.
- Un système d'enregistrement graphique

La figure ci-dessous présente un électrocardiogramme(ECG) normal montrant les différentes ondes (P, QRS, T, U) ainsi que les segments et intervalles caractéristiques. L' montre également les différents intervalles et segments importants comme l'**intervalle P-R**, le **segment S-T** et l'**intervalle Q-T**.

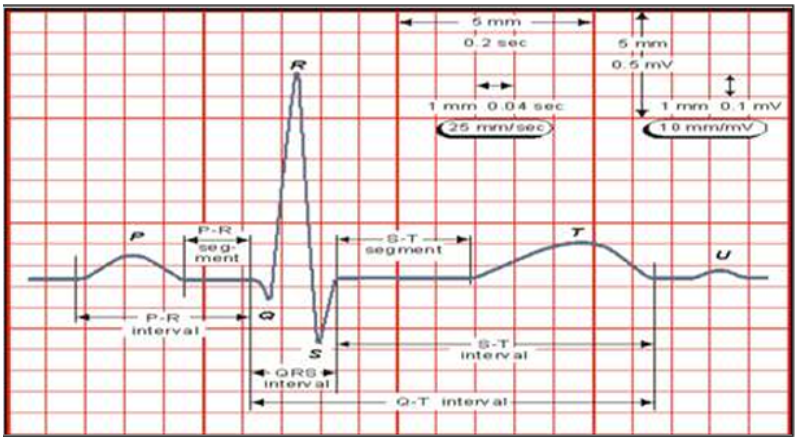

Figure 1.1 : Electrocardiogramme

2-1. Dérivations électrocardiographiques :

L'ECG standard est enregistré sur 12 dérivations ou il examine le potentiel électrique du cœur de 12 points de vue différents.**[1]**

2-1-1. Les dérivations bipolaires (Einthoven):

➢ I(D1) : elle enregistre les différences de potentiel électrique entre le poignet droit (right : R) et le poignet gauche (left : L).

➢ II(D2) : elle enregistre les différences de potentiel électrique entre le poignet gauche (left : L) et la jambe gauche (foot : F).

➢ III(D3) : enregistre les différences de potentiel électrique entre le poignet droit (right : R) et la jambe gauche (foot : F).

Ces trois dérivations forment le triangle équilatéral d'Einthoven le montage des polarités étant tel que D2=D1+D3.

2-1-2 . Les dérivations unipolaires (Wilson) :

➢ AVL (left) pour l'avant-bras gauche.

➢ AVR (right) pour l'avant-bras droit.

➢ AVF (foot) pour la jambe gauche.

2-1-3. Les dérivations standards (précordiales) :

➢ V1 : 4e espace intercostal à droite du sternum.

➢ V2 : 4e espace intercostal à gauche du sternum.

➢V3 : à mi-chemin entre V2 et V4.

➢V4 : 5e espace intercostal sur la ligne claviculaire moyenne.

➢V5 : Ligne axillaire antérieure (mi-chemin entre V4 et V6).

➢V6 : Lignes axillaires moyennes à la hauteur du V4.

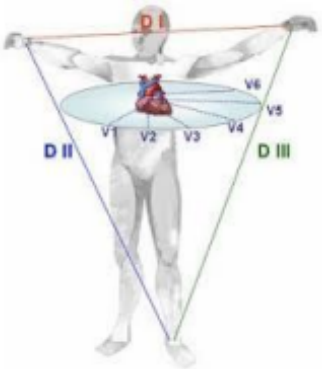

Figure 1.2 : Les 12 dérivations de l' ECG

3.Tracé électrique du coeur :

Cette figure représente un électrocardiogramme (ECG) schématique, illustrant les différentes phases de l'activité électrique du cœur lors d'un cycle cardiaque. [5]

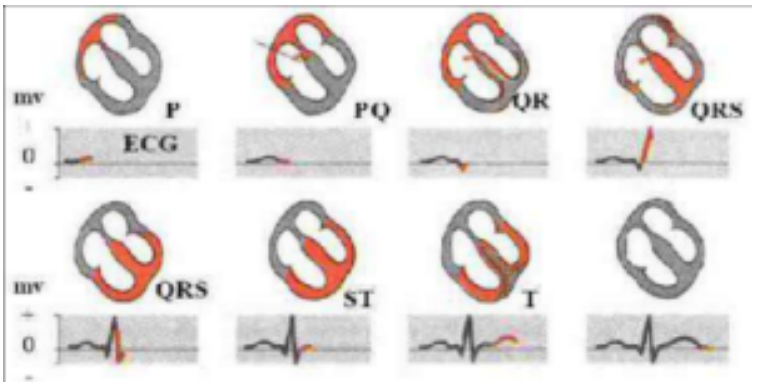

Figure 1.3 : L'onde électrique d'un battement de coeur

Le tracé révèle les étapes clés du cycle cardiaque à travers une série de pics et de creux :

- Première légère bosse (Onde P) : Signale l'activation des oreillettes, comme une petite vague précédant la contraction.
- Une ligne plate suivie d'un pic abrupt (Segment PQ et complexe QRS) :
    - La partie plate (PQ) marque une pause électrique, le temps que l'impulsion traverse le cœur.
    - Le pic en forme d'éclair (QRS) montre l'emballement des ventricules qui se contractent violemment.
- Un plateau légèrement incurvé (Segment ST) : Indique que les ventricules sont en pleine contraction, stabilisés électriquement.

- Une dernière bosse arrondie (Onde T) : Symbolise la "recharge" des ventricules, comme un retour au calme après l'effort.

4 . Les paramètres du signal ECG :

4-1.Ondes Intervalles et Segments:

➢ **Onde P :** L'onde P sur l'ECG, correspond à la dépolarisation (et la contraction) des oreillettes.

➢ **Intervalle PR (ou PQ) :** Est le temps entre le début de P et le début du QRS. Sa durée normale, mesurée du début de l'onde P au début du complexe QRS est de 0,12 à 0,20 seconde. La durée de l'espace PR diminue lorsque la fréquence cardiaque augmente. Il est normalement isoélectrique.

➢ **Segment PR (pause du nœud AV) :** Le segment PR correspond au délai entre la fin de la dépolarisation des oreillettes et le début de celle des ventricules. C'est le temps pendant lequel l'onde de dépolarisation est bloquée au niveau du nœud AV.

➢ **Onde QRS :** Correspondant à la dépolarisation des ventricules et de grande amplitude (signal de quelques millivolts), car la masse des ventricules est très supérieure à celle des oreillettes; Sa durée normale vaut entre 85 et 95 ms.

➢ **L'Intervalle QRS :** La durée de cet intervalle représente le temps de dépolarisation ventriculaire.

➢ **Segment ST (durée de stimulation complète des ventricules) :** Le segment ST correspond à la phase pendant laquelle les cellules ventriculaires sont toutes dépolarisées, le segment est alors isoélectrique.

➢ **Intervalle QT :** L'intervalle QT indique la durée des ventricules de la

dépolarisation à la repolarisation. La région commence au début du complexe QRS et s'étend jusqu'au point final du T. La durée varie en fonction du sexe, de l'ancienneté et du rythme cardiaque.

➤ **Onde T :** Elle correspond à la repolarisation des ventricules. L'onde T normale à une amplitude plus faible que le complexe QRS.

➤ **Onde U :** est une petite déflexion parfois observée après l'onde T dans les dérivations précordiales V à V4. Elle est positive dans toutes les dérivations sauf en a VR, sa présence traduit une anomalie métabolique.

➤ **Intervalle RR :** L'intervalle RR est mesuré en tant que temps entre l'onde R de deux battements de cœur adjacents. Les intervalles RR sont normalement réguliers, mais l'irrégularité des intervalles RR peut être due à une maladie du nœud du sinus ou à une arythmie supraventriculaire.[5]

Figure 1.4 : Nomenclature standardisée par l'ECG

4-2. fréquence :

La fréquence cardiaque est le nombre de battements par minute (bpm). Elle est liée au nombre de cycles cardiaques (ou complexes QRS) par seconde. Pour calculer on a deux cas : rythme régulier et rythme irrégulier.

4-2-1. Rythme Régulier :

Quand le rythme est régulier, les intervalles entre deux pics R (les intervalles RR) sont à peu près égaux.

➤ **Fréquence (en bpm)** = 60/ (intervalle RR(en secondes) (1)

4-2-2. Rythme Irrégulier :

Quand le rythme est irrégulier, les intervalles RR varient beaucoup.On mesure plusieurs intervalles RR (au moins 5 à 10) puis on calcule la moyenne des intervalles RR en secondes :

moyenne RR = ∑RRi \ n (2)

où RRi est chaque intervalle RR mesuré.

➤ **Fréquence moyenne (en bpm)** = 60 / (moyenne RR) (3)

- **fréquence normale (Adulte au repos)** : entre 60 et 100 bpm
- < 60 bpm : **bradycardie**
- 100 bpm : **tachycardie**

4-3. Amplitude:

L'amplitude du signal ECG correspond à la variation de tension électrique enregistrée à la surface de la peau, exprimée en millivolts (mV).

- **Onde P :** ~ 0.1 à 0.2 mV
- **Complexe QRS :** ~ 1 à 1.5 mV
- **Onde T :** ~ 0.1 à 0.5 mV

5 . Acquisition d’un signal ECG :

Acquérir un signal c'est récupérer une information numérique ou analogique par un système ou une chaîne d'acquisition, qui est l'ensemble des éléments nécessaire à la capture et l'exploitation d'une donnée puis la transmission jusqu'au récepteur. L'utilisateur peut ensuite vouloir utiliser ces données immédiatement ou les stocker pour les utiliser ultérieurement.

L'acquisition du signal se fait généralement par un dispositif électronique qui est le capteur afin de capter la grandeur physique et la transformer en un signal électrique, puis en passant par le conditionneur un circuit électronique qui intervient entre le capteur et l'interface d'où son objectif est essentiellement l'amplification et le pré-filtrage des signaux issus du capteur.[6]

Le système d'acquisition est constitué de différents étages ayant pour but de convertir les signaux en données numériques pouvant être transmises par voie aérienne. Son caractère portatif impose une alimentation autonome (pile) et la limitation de l'encombrement du système. Les différentes étapes que subit le signal afin de le numériser sont les suivantes :

•**Capteur :** Consiste à convertir un signal quelconque (physique) en un signal électrique, dans notre cas la différence de potentiel entre deux points du corps est traduite en un signal électrique.

• **Pré-amplification :** Le signal issu des électrodes étant de faible amplitude, un amplificateur est nécessaire afin de le rendre exploitable.

• **Pré-filtrage :** Permet d'éliminer les bruits de haute et de basse fréquence et garder le signal utile.

• **Amplification finale :** Ajuste le niveau du signal à la **plage d'entrée du convertisseur analogique-numérique (CAN) .**

• **Conversion analogique-numérique (CAN ou ADC):**Transforme le signal analogique (continu) en **signal numérique** (discret) pouvant être traité par un microcontrôleur.

• **Traitement numérique (dans un microcontrôleur ou DSP):**

- ○ Filtrage numérique supplémentaire,
- ○ Détection des ondes P, QRS, T,
- ○ Analyse de rythme, détection d'anomalies,
- ○ Compression des données si nécessaire.

• **Stockage ou transmission des données:**

Deux options possibles :

- ○ **Stockage local** sur une carte mémoire.
- ○ **Transmission sans fil** via **Bluetooth, Wi-Fi ou radio fréquence (RF)** vers un smartphone, une station médicale ou un cloud.

• **Alimentation du système :** Généralement assurée par une pile ou batterie rechargeable, avec un circuit de gestion de l'énergie pour assurer l'autonomie et la sécurité électrique du patient.

6.Conclusion :

Dans ce chapitre nous avons présenté l'origine et la structure du signal électrocardiogramme (ECG), ses différentes composantes (onde P, complexe QRS, onde T) ainsi que les paramètres cliniques essentiels qu'il permet d'extraire. Nous

avons également décrit le système d'acquisition du signal, depuis les électrodes jusqu' à l' alimentation du système. Le chapitre suivant sera donc consacré aux différentes méthodes d'extraction des paramètres à partir du signal ECG.

Chapitre 2 : Extraction et traitement du signal ECG

1. Introduction :

Le signal électrocardiographique (ECG) constitue un outil essentiel dans l'évaluation et le diagnostic des pathologies cardiaques. Toutefois, la qualité du signal brut est souvent altérée par différents types de bruits, rendant indispensable l'application de techniques de traitement adaptées pour en extraire des caractéristiques fiables.

Dans ce chapitre, nous présenterons d'abord les principales sources de bruit affectant les enregistrements ECG ainsi que les méthodes employées pour leur atténuation. Nous poursuivrons avec l'étude des techniques d'extraction des caractéristiques, en mettant particulièrement en avant la méthode de Pan-Tompkins, reconnue pour son efficacité dans la détection des complexes QRS. Cette méthode servira de base pour les travaux ultérieurs, où nous explorerons les caractéristiques extraites en appliquant des algorithmes de machine learning afin de développer un système automatisé de diagnostic des pathologies cardiaques.

2.Les types de bruits présents dans l'ECG :

Sur tout enregistrement électrocardiographique il peut apparaître des événements indésirables pouvant brouiller le tracé et, parfois, induire en erreur le diagnostic final. Ces bruits sont reconnaissables par l'œil expérimenté qui les identifie avant d'effectuer son diagnostic.[07] Ces bruits peuvent être classés selon leur origines en deux grandes catégories, les bruits d'origine technique et les bruits physiques.[4]

2-1.Bruits techniques :

Le matériel utilisé lors de l'enregistrement doit être manipulé avec précaution car il peut être source de bruits lors de l'enregistrement dont Les plus courants :

2-1-1.Bruit dû au secteur :

Ce type de bruit apparaît sur tout l'enregistrement et peut être assez fort mais il s'élimine facilement avec un filtre sélectif car c'est un bruit haute fréquence à bande étroite.[4]

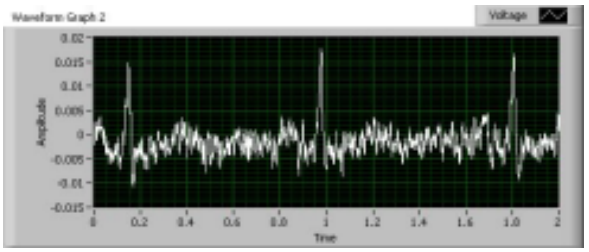

Figure 2.1 : Bruit du secteur

2-1-2. Bruit dû au mauvais contact électrode-peau :

Lorsque les électrodes utilisées pour le recueil du signal ECG se détachent ou le gel entre l'électrode et la peau se sèche,cela peut provoquer un bruit qui provoque des changements brusques de l'amplitude du signal d'ECG ,ainsi que de faibles changements de fréquence de référence.

De plus , une mauvaise conductivité entre les électrodes et la peau peut avoir un effet sur le signal ECG qui peut aller d'une simple diminution d'amplitude a l'apparition des pics qui peuvent parfois être confondus avec les ondes du tracé normal.

Ce type de bruit intermittent à bande spectrale large s'élimine difficilement car son énergie se trouve dans la même gamme de fréquence que le complexe QRS.[4]

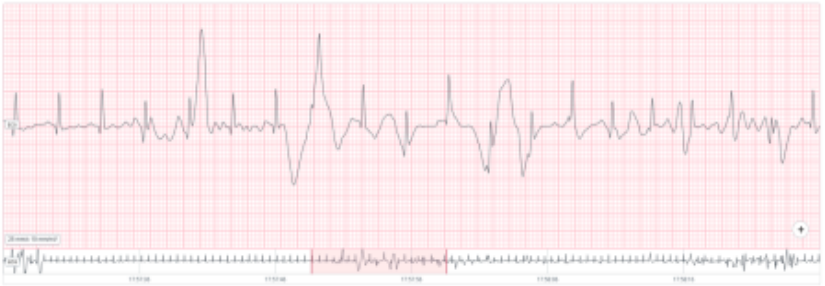

Figure 2.2 : Les bruits dus mauvais contact électrode-peau

2-1-3.Autres bruits :

Parmi les bruits courants on peut citer les artefacts dus aux mouvements des câbles électriques, la saturation des instruments de mesure, les mauvais câblages, les artefacts dus au port de vêtements synthétiques, etc.

2-1.Bruits Physiques :

Les bruits physiques sont liés à des facteurs externes qui affectent le signal ECG, tels que les mouvements corporels(respiration), les activités involontaires(contracture musculaire) ou des variations environnementales. Ces bruits sont souvent plus difficiles à éliminer que les bruits techniques.

2-1-1.Mouvements de la ligne de base :

Ce type de bruits se traduisant par un mouvement lent de l'ensemble du tracé vers le haut ou vers le bas de manière cyclique ou irrégulière.
Elle ne modifie pas directement la forme des ondes ECG (P, QRS, T), mais perturbe leur position verticale, ce qui peut compliquer l'analyse automatique du signal, notamment le calcul de l'amplitude des ondes ou la détection précise des pics.[7]

Ces perturbations sont généralement peu gênantes pour l'analyse de l'ECG et peuvent être en grande partie filtrées car leur énergie se situe dans une bande de fréquence basse, qui empiète peu sur celle de l'ECG normal.[4]

2-1-2.Bruit myoélectrique ou tremblement somatique :

Ces perturbations sont assez gênantes lorsque le patient bouge beaucoup ou lorsqu'il frissonne, elles peuvent noyer les ondes P et T et empêcher un diagnostic fiable.

L'apparition de ces perturbations dépend de l'état du patient, s'il est très tendu ou atteint de maladie de Parkinson, l'enregistrement peut être de mauvaise

qualité sur toutes les voies de l'ECG.

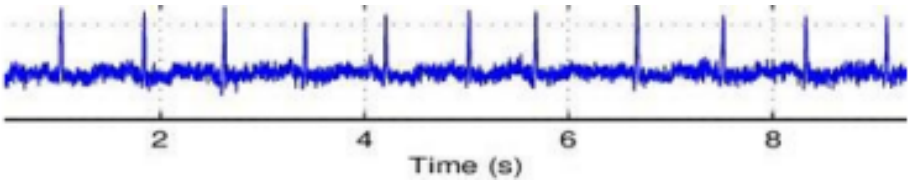

Figure 2.3 : Bruit généré par le mouvement du patient

3.Extraction des paramètres du signal ECG :

L'Étape d'extraction des caractéristiques est la clé du succès de la classification des battements cardiaques à l'aide du signal ECG. Toute information extraite de la pulsation utilisée pour discriminer son type peut être considérée comme une caractéristique. Les caractéristiques peuvent être extraites sous différentes formes directement à partir de la morphologie du signal
ECG dans le domaine temporel et/ ou dans le domaine fréquentiel.
L'extraction des caractéristiques est un processus de réduction de dimensionnalité par lequel un ensemble initial de données brutes est réduit à des groupes plus gérables pour le traitement,
qui va souvent de pair avec la classification. Cette étape réduisant efficacement la quantité de données à traiter, tout en décrivant toujours avec précision et complètement l'ensemble de données d'origine. L'étape de l'extraction est utile lorsque vous devez réduire le nombre de ressources au traitement sans perdre d' informations importantes ou pertinentes. Une caractéristique est une valeur décrivant une propriété des signaux ECG, les caractéristiques sont généralement regroupées dans un vecteur qu'on appelle vecteur de caractéristiques [9]. Après les opérations de prétraitement (filtrage...etc.), il est nécessaire
d'extraire les caractéristiques des signaux ECG afin de les utiliser dans la phase de classification. Les approches existantes ont été regroupées en deux catégories principales : fiduciaire et non fiduciaire [10].

➢ **Approches fiduciaires :** sont les méthodes les plus utilisées pour faire l'extraction des attributs d'un signal ECG (les pics, les intervalles, les pentes ou d'autre mesures d'une onde qui sont simplement basées sur l'information

temporelle et morphologique lesquelles apparaissent au fur et à mesure d'un rythme cardiaque ECG.

➢ **Approches non fiduciaires :** les caractéristiques naturelles d'un signal ECG ont fait un grand effet sur localisation d'une information invariante dans le temps, celle-ci peut être considéré un challenge dans le traitement des signaux non stationnaire, l'information fréquentielle a montré un atout dans plusieurs domaines, la transforme de Fourier, Ondelette...etc. sont des outils utilisés pour extraire ces informations . Le but du processus d'extraction de caractéristiques est de sélectionner et de conserver les informations pertinentes à partir du signal d'origine.

3-1.Prétraitement du signal ECG :

TABLE 2.1– Étapes de prétraitement du signal ECG et leurs objectifs

Étape de prétraitement	***But***
➢ Un filtrage passe-bande (0.5–40Hz)	Conserver les composantes physiologiques
➢ Un filtre notch centré à 50 Hz	Conserver les composantes physiologiques
➢ Conserver les composantes physiologiques	Stabiliser la ligne isoélectrique → utile pour détecter les ondes P et T
➢ Un débruitage par ondelettes discrètes (DWT)	Atténuer le bruit tout en préservant la morphologie des ondes ECG

Le signal ECG brut est souvent affecté par différents types de bruits, tels que les

interférences de fréquence secteur (50 Hz), les artefacts dus aux mouvements du patient, et la dérive de la ligne de base provoquée par la respiration.

Ces perturbations peuvent fausser l'analyse du signal, en rendant difficile voire impossible la détection correcte des points caractéristiques tels que les pics R, et par conséquent l'extraction des paramètres électrocardiographiques (PR, QRS, QT, RR...).

Le prétraitement est une étape indispensable dans toute chaîne de traitement du signal ECG. Il permet de supprimer les composantes de bruit haute et basse fréquence, de stabiliser la ligne isoélectrique,etc

3-2 Méthodes d'extraction :

3-2-1.Méthodes en domaine temporel (Time Domain):

La méthode temporelle repose sur l'analyse directe du signal ECG tel qu'il apparaît dans le temps. Elle vise à détecter les différentes ondes caractéristiques : **P**, **QRS**, et **T**. La détection du complexe QRS est souvent réalisée avec des algorithmes comme **Pan-Tompkins**, qui identifient les pics R grâce à un enchaînement de filtrage, différentiation, dérivation et
seuillage. Une fois les ondes détectées, on peut extraire des paramètres essentiels : l'**intervalle RR** (entre deux pics R), l'**intervalle PR**, le **segment ST**, ou encore la **durée du complexe QRS**.

3-2-2.Méthodes en domaine fréquentiel (Frequency Domain) :

Cette méthode repose sur la transformation du signal ECG en domaine fréquentiel via la Transformée de Fourier (FFT).
Elle permet d'analyser le contenu spectral du signal, c'est-à-dire la manière dont l'énergie est répartie dans les différentes bandes de fréquence. Elle est principalement utilisée pour étudier la variabilité de la fréquence cardiaque .

- ***Paramètres extraits :*** Composantes spectrales dominantes, analyse du

contenu basse fréquence pour détecter certaines arythmies.

Cette méthode moins précise pour la localisation “ Manque de précision temporelle” (ne convient pas à la détection d’événements transitoires comme les pics R.), mais utiles pour des analyses globales (par exemple, la fréquence cardiaque, ou la détection de bruit/anomalies).

3-2-3.Méthode temps-fréquence (Time-Frequency Domain) :

Cette méthode combine à la fois l’information temporelle et fréquentielle, ce qui la rend idéale pour les signaux non stationnaires comme l’ECG. Les techniques les plus courantes sont la transformée en ondelette discrète (DWT).
Elles permettent d’analyser comment les composantes fréquentielles du signal évoluent dans le temps.

3-2-4.Méthodes d’intelligence artificielle (IA) :

Avec l’essor du machine learning et du deep learning, de nouvelles approches automatiques permettent d’extraire les paramètres ECG sans étape de prétraitement explicite. Les réseaux de neurones convolutifs (CNN) sont souvent utilisés pour analyser directement les signaux ECG bruts, détecter les ondes caractéristiques, ou classifier des pathologies (fibrillation auriculaire, tachycardie, etc.).
Ces réseaux apprennent automatiquement les patterns caractéristiques du signal via un grand nombre de données annotées.
Ce sont les approches modernes. Depuis 2015, presque toutes les recherches sur l’analyse ECG automatique utilisent le ML ou le DL pour la classification ou la détection.

4. L'extraction par la méthode Pan and Tompkins :

Les travaux de Pan and Tompkins influencent grandement la détection du complexe QRS par rapport à d'autres. Cette technique est l'un des algorithmes les plus importants pour la détection des complexes QRS. Partout où la précision de l'extraction de la forme d'onde de l'électrocardiogramme (ECG) joue un rôle essentiel dans l'amélioration du diagnostic de toutes maladies cardiaques.

L'ECG normal devrait être composé de plusieurs parties, notamment l'onde P ,le complexe QRS et l'onde T, ces ondes reflètent l'activité du cœur , telle que l'onde P produite par la contraction musculaire des oreillettes et sa durée indique l'élargissement des oreillettes.

L'onde Q donne la première valeur négative et est généralement censée être inférieure de 25 % à la valeur de l'onde R.

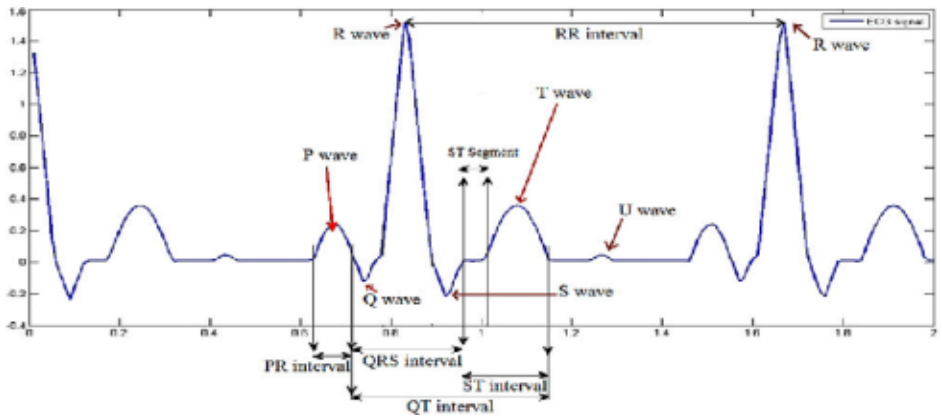

Figure 2.5 : Caractéristiques d'un battement cardiaque

L'algorithme de Pan and Tompkins est basé sur des analyses numériques des pentes, de l' amplitude et la largeur.

La méthodologie suivie est que l'ECG passe à travers un filtre passe-bande numérique spéciale, Il peut réduire les fausses détections causées par les

différents types d'interférences présentes dans le signal ECG. Ensuite le signal filtré passe par les phases de dérivation, de quadrature.

Enfin un seuil adaptatif est appliqué. L'algorithme ajuste automatiquement les seuils et les paramètres périodiques pour adapter les changements de la morphologie du QRS.

4-1. Détection du complexe QRS :

Les différentes étapes de l'algorithme sont illustrées dans la figure suivante :

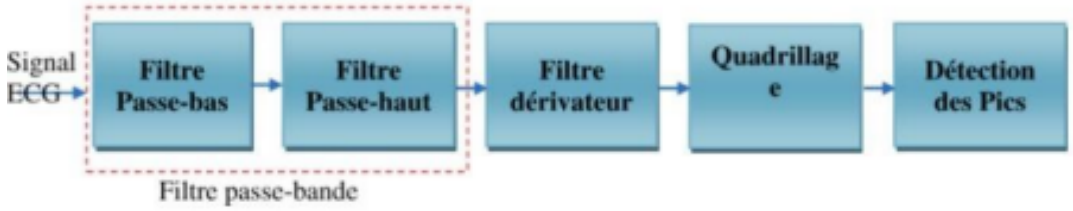

Figure 2.6 : Les étapes de la méthode Pan and Tompkins

Le signal passe par des phases de filtrage, de dérivation, d'élévation au carrée avant que les pics soient détectés.

❖ Filtre passe-bande :

Dans la première étape, le signal passe à travers un filtre passe-bande.

Le filtre passe bande de réduit le bruit dans le signal ECG en s'adaptant au spectre du complexe QRS.

Cela atténue le bruit dû aux influences musculaires, aux interférences des lignes électriques et à la déviation de la ligne de base. Le filtre mis en Suivre dans cet algorithme est composé de filtre passe haut et passe bas en cascade

- **filtre passe bas :**

Le signal obtenu est filtré par un filtre passe-bas afin d'enlever le bruit de hautes

fréquences résiduelles, et d'obtenir un maximum unique pour chaque complexe. Notre filtre a une fréquence de coupure de 20 Hz. Ce qui nous permet d'éliminer les ondulations dues au réseau de 50Hz.

✓ **La fonction de transfert du filtre passe bas est données par l'équation :**

$$H(z) = \frac{\left(1-z^{-6}\right)^2}{\left(1-z^{-1}\right)^2} \quad (4)$$

- **filtre passe haut :**

Le signal est traité ensuite par un filtre passe haut. Ce filtre élimine toutes les basses fréquences qui n'appartiennent pas au signal ECG. La fréquence de coupure de ce filtre est de 5 Hz. Ce filtre élimine complètement les bruits relatifs à la variation de la ligne de base, la respiration, ainsi que tous autres artefacts liés à des mouvements du patient.

✓ **La fonction de transfert du filtre passe bas est données par l'équation :**

$$H(z) = z^{-16} - \frac{\left(1-z^{-32}\right)}{\left(1-z^{-1}\right)} \quad (5)$$

❖ Filtre dérivateur :

L'étape de traitement suivante se fait par l'application d'un filtre dérivateur, qui est une technique standard pour trouver les pentes élevées qui distinguent normalement les Complexe QRS des autres ondes ECG.

La procédure dérivée supprime les composantes basse fréquence des ondes P et T, et fournit un gain important aux composantes haute fréquence provenant des pentes élevées du complexe QRS.

✓ **La fonction de transfert du filtre dérivateur est donnée par :**

$$H(z) = \frac{1}{8T}\left(-z^{-2} - 2z^{-1} + 2z^{1} + z^{2}\right) \quad (6)$$

✓ **L'équation récursive permettant de calculer le dérivé premier est donnée par la relation suivante :**

$$x(k) = ECG(k - 1) - ECG(k + 1) \quad (7)$$

✓ **Le dérivé deuxième est calculé en utilisant la formule :**

$$y(k) = -2 * ECG(k - 2) - ECG(k - 1) + ECG(k + 1) + 2 * ECG(k + 2) \quad (8)$$

❖ Quadrillage :

L'opération de quadrillage rend le résultat positif et met en évidence les grandes différences résultant des complexes QRS , les petites différences résultant des ondes P et T sont supprimées. Les composantes haute fréquence du signal liées au complexe QRS sont encore améliorées. Il s'agit d'une transformation non linéaire qui consiste à élever au carré point par point les échantillons du segment

✓ **L'équation de cette étape est :**

$Y = \alpha x + \beta \mathbf{y}$ (9)

Tel que :

α et β des coefficients inférieurs à 1 et $\alpha + \beta = 1$

Finalement la forme d'onde carrée passe à travers un intégrateur de fenêtre mobile. Ce dernier a pour objectif d'obtenir sous forme d'onde des informations supplémentaires en plus de la pente de l'onde R.

L'étape suivante est l' intégration du signal. Cette opération produit un signal contenant les informations concernant la pente et la largeur du complexe QRS.

La taille de la fenêtre d'intégration doit être adaptée à la largeur moyenne d'un complexe QRS. Si elle est trop grande, le maximum est décalé en temps par rapport à la position du R, au contraire, elle est petite on obtient plusieurs pics pour une même onde R. après l'intégration de signal, le signal disponible possède un maximum absolu pour chaque Complexe QRS [8].

Finalement le complexe QRS sera détecté, les pics locaux du signal intégré sont trouvés. Un pic est défini comme le point dont le signal change de direction (de direction croissante à une direction décroissante), il important de suivre l'évolution des paramètre cycle par cycle afin d'obtenir le vecteur caractéristique qui contient quelques paramètres qui sont : les amplitudes des pics, l'intervalle RR puisque son évolution permet de suivre au cours du temps le rythme cardiaque, et les différents intervalles entre différents pics.

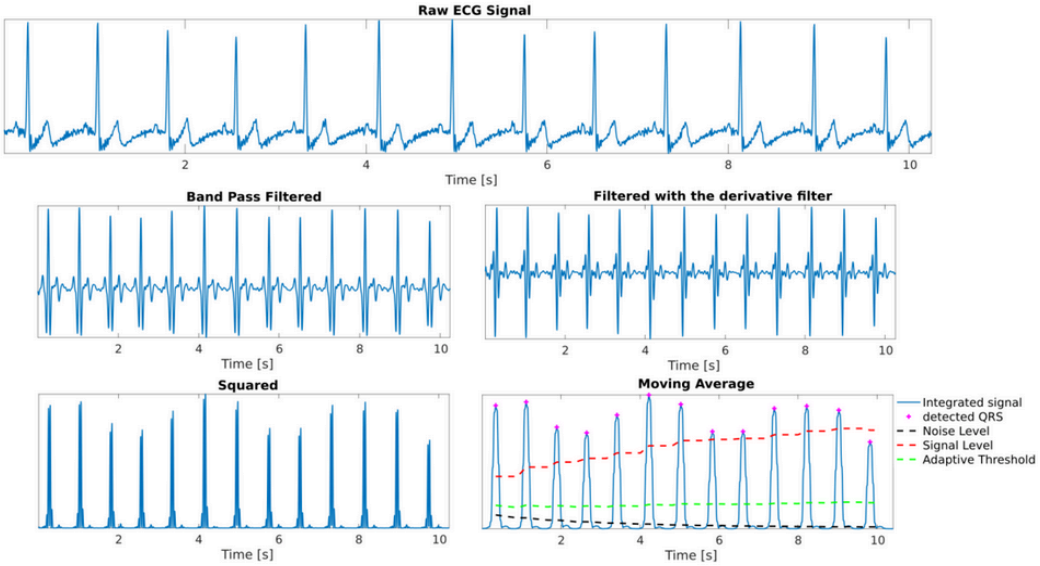

Figure 2.7 : Étapes clés du traitement du signal ECG par la méthode de Pan-Tompkins

Après la détection de ces différents instants caractéristiques de chacune des ondes de l'ECG, nous pouvons maintenant classifier les battements cardiaques à travers le vecteur caractéristique.

4-2 Justification du choix de la méthode d'extraction :

Dans le cadre de l'extraction des paramètres du signal ECG, l'algorithme de Pan-Tompkins a été sélectionné en raison de ses performances éprouvées et de son adéquation avec les exigences d'un diagnostic assisté par machine learning.

Cette méthode est particulièrement reconnue pour sa robustesse face aux bruits et artefacts, garantissant ainsi une détection fiable des complexes QRS, éléments centraux pour l'analyse de l'activité cardiaque.

Par ailleurs, la simplicité de son implémentation et sa capacité à fonctionner en temps réel constituent des atouts majeurs, notamment dans des applications médicales nécessitant rapidité et efficacité. La détection précise des complexes QRS par Pan-Tompkins facilite également l'identification des ondes P et T, permettant l'extraction de caractéristiques temporelles essentielles telles que les intervalles PR, QT et RR ainsi que les amplitudes des différentes ondes.

Comparée à d'autres méthodes plus sophistiquées, telles que celles basées sur la transformée en ondelettes ou l'apprentissage profond, la méthode de Pan-Tompkins présente l'avantage
d'une faible complexité algorithmique, d'une meilleure interprétabilité des résultats et d'une consommation réduite en ressources de calcul. Ce choix s'inscrit ainsi dans une logique d'efficacité et de fiabilité, tout en assurant une extraction rapide et pertinente des paramètres pour l'entraînement d'un modèle de machine learning destiné au diagnostic de pathologies cardiaques

5.Conclusion :

Dans ce chapitre, nous avons introduit les concepts fondamentaux liés à l'étape d'extraction des caractéristiques, en abordant également les différents types de bruits présents dans le signal ECG ainsi que les principales méthodes permettant leur atténuation. Parmi les techniques présentées, la méthode de Pan-Tompkins a été détaillée et sera exploitée dans le troisième chapitre pour extraire efficacement les caractéristiques des battements cardiaques. Ces caractéristiques seront ensuite utilisées dans le cadre de méthodes de machine learning afin de développer un système de diagnostic automatique des pathologies cardiaques.

Chapitre 3 : Détection des pathologies cardiaques

1. Introduction

Dans ce chapitre, nous décrivons la méthodologie adoptée pour le traitement et l'analyse des signaux ECG. Après la présentation de la base de données utilisée, nous détaillons les étapes de prétraitement, d'extraction des caractéristiques à l'aide de l'algorithme de Pan-Tompkins, puis l'entraînement et l'évaluation de trois modèles de classification dans le but de diagnostiquer différentes pathologies cardiaques.

2.Recherche Des Données

La base de données PTB Diagnostic ECG Database (PTB-DB), hébergée sur PhysioNet, constitue le matériau expérimental de ce travail. Elle réunit les électrocardiogrammes haute résolution de 294 patients enregistrés au Deutsches Herzzentrum de Berlin entre 1990 et 1996 Chaque patient dispose d'un à trois tracés, soit 549 enregistrements au total. Chaque enregistrement se compose d'un couple de fichiers : un header (.hea) contenant les métadonnées — 15 dérivations (12 standard + 3 Frank XYZ), fréquence d'échantillonnage à 1 000 Hz, durée moyenne de 120 s, ainsi qu'une rubrique # Diagnostic: rédigée par un cardiologue — et un fichier données brutes (.dat) codant les valeurs ADC sur 16 bits.

L’ensemble des chemins relatifs est consigné dans un fichier texte unique , RECORDS qui joue le rôle d’index maître : il liste , ligne par ligne , le chemin relatif (sans extension) de chaque tracé ECG présent dans la base PTB-DB.

Dans la base de données, chaque ligne comme 1.0.0/patient 001/s0010_re correspond à un enregistrement ECG. Elle est liée à deux fichiers : s0010_re.hea et s0010_re.dat .

Chaque enregistrement ECG est listé dans le fichier RECORDS sous la forme suivante :

1.0.0/patient001/s0010_re .

Ce chemin correspond à deux fichiers essentiels :

- **1.0.0/patient001/s0010_re.hea :** un fichier *header* contenant les métadonnées de l’enregistrement (fréquence d’échantillonnage, gains, nombre de dérivations, annotations cliniques via le champ # Diagnostic:),

- **1.0.0/patient001/s0010_re.dat** : un fichier binaire contenant les données brutes du signal ECG sur 15 dérivations, encodées sur 16 bits.

Cette organisation garantit l’exhaustivité du parcours de données et la reproductibilité de l’ensemble des traitements.

Un contrôle d’intégrité a permis de vérifier que les **549 fichiers attendus** étaient bien présents et exploitables (549/549).

Toutefois, les diagnostics contenus dans le champ # Diagnostic: présentent une grande hétérogénéité terminologique. Afin de faciliter l’analyse et la classification automatique, ces diagnostics ont été regroupés en cinq classes cliniquement pertinentes, comme suit :

- **AMI (Acute Myocardial Infarction)** :

  ['stemi', 'nstemi', 'myocardial infarction']

- **Arrhythmia** :

  ['afib', 'vtac', 'bradycardia']

- **Ischemia** :

['ischemia', 'st depression']

- **Cardiomyopathy** :

  ['dcm', 'hcm']

- **Normal** :

  ['normal', 'healthy control']

Ce regroupement permet d'améliorer la robustesse des modèles de classification tout en conservant la pertinence clinique des diagnostics .

Cette base, riche par sa résolution temporelle et la diversité de ses annotations, offre ainsi un terrain d'évaluation robuste pour nos algorithmes de détection automatique d'anomalies cardiaques.

3. Outils utilisés

3-1. Google Colab :

Google Colab est un environnement de développement intégré (IDE) basé sur le cloud qui permet d'exécuter du code Python. Il offre un espace de travail en ligne où nous pouvons écrire, exécuter et collaborer sur du code Python sans avoir à installer quoi que ce soit localement sur votre machine. Google Colab fournit également des ressources de calcul gratuites, y compris l'accès à des processeurs graphiques (GPU) et des unités de traitement tensoriel (TPU) pour accélérer les calculs intensifs.

figure 3.1.Google Colab

3-2 .Python :

Python est un langage de programmation polyvalent et largement utilisé dans le domaine de l'analyse de données et de la science des données. Il offre une syntaxe simple et lisible, ainsi qu'une vaste gamme de bibliothèques et de packages pour diverses tâches, y compris l'analyse de séries temporelles. Python est particulièrement apprécié pour sa facilité d'apprentissage, sa flexibilité et sa grande communauté de développeurs qui contribuent à son écosystème.

figure 3.2. Python

3-3. NumPy :

NumPy est une bibliothèque open-source pour Python, qui fournit des structures de données et des fonctions pour travailler efficacement avec des tableaux multidimensionnels et des matrices. Elle offre des outils pour effectuer des calculs numériques complexes, notamment des opérations mathématiques, des manipulations de données, des transformations de Fourier, des algèbres linéaires et bien plus encore.

figure 3.3.NumPy

3-4. Matplotlib :

Matplotlib est une bibliothèque Python utilisée pour créer des visualisations de données sous forme de graphiques, de diagrammes et de tracés. Elle offre une grande flexibilité pour la création de différents types de graphiques, tels que les graphiques linéaires, les histogrammes, les diagrammes en barres, les nuages de points, les diagrammes circulaires, etc. Matplotlib est largement utilisée dans les domaines de la science des données, de la recherche, de la visualisation de données et de l'analyse statistique.

figure 3.4.Matplotlib

3-5.Wfdb :

La bibliothèque WFDB (WaveForm DataBase) est une bibliothèque logicielle open-source développée à l'origine par le MIT (Massachusetts Institute of Technology) dans le cadre du projet PhysioNet. Elle est principalement utilisée pour manipuler, analyser et visualiser des signaux physiologiques, notamment les signaux ECG (lire les fichiers .dat et .hea).

3-6.Scipy.signal :

Scipy.signal est un module de la bibliothèque SciPy en Python, spécialisé dans le traitement du signal. Il fournit des outils pour filtrer, transformer, analyser et manipuler des signaux (comme les signaux ECG, audio, etc.). Ses fonctions principales sont : Filtres numériques ,Transformées (Fourier,convolutions, corrélation) Détection de pics (findpeaks),Conception et application de filtres passe-bas, passe-haut…

figure 3.5.Scipy.signal

3-7. Scikit-learn :

Scikit-learn (anciennement scikits.learn et également connu sous le nom de sklearn) est une bibliothèque d'apprentissage automatique gratuite et open source pour le langage de programmation Python . Elle propose divers algorithmes de classification , de régression et de clustering , notamment les machines à vecteurs de support , les forêts aléatoires(Random Forest) , le boosting de gradient , *les k* -moyennes et DBSCAN . Elle est conçue pour interagir avec les bibliothèques numériques et scientifiques Python NumPy et SciPy .

3-8.NeuroKit2 :

NeuroKit est une bibliothèque open source en Python destinée à la collecte, au traitement et à l'analyse des signaux physiologiques tels que l'électrocardiogramme (ECG), l'électroencéphalogramme (EEG), la conductance de la peau, et d'autres mesures liées aux réponses neurophysiologiques. Elle vise à simplifier et automatiser les étapes complexes du prétraitement des données physiologiques pour les chercheurs en sciences du comportement et en neurosciences.

4. Prétraitement des signaux ECG

Le prétraitement des signaux ECG a été réalisé à l'aide de la fonction **ecg_clean()** de la bibliothèque **NeuroKit2**, qui applique un nettoyage automatique du signal. Cette étape permet de corriger les artefacts, de stabiliser la ligne de base et de lisser les fluctuations indésirables, tout en préservant la morphologie des ondes cardiaques essentielles (P, QRS, T).

Une fois nettoyés, les signaux sont **rééchantillonnés à une fréquence de 100Hz**, ce qui

permet de normaliser la résolution temporelle et de garantir une longueur constante de **5000 échantillons** pour chaque enregistrement. Ce format unifié est crucial pour assurer une cohérence lors de l'extraction des caractéristiques et pour l'apprentissage supervisé.

Parallèlement, une **visualisation graphique** a été réalisée à l'aide de **Matplotlib**, où les signaux traités sont tracés avec les **pics R détectés** automatiquement mis en évidence. Cette superposition visuelle permet de valider qualitativement la précision du traitement et de la détection des cycles cardiaques.

5. Extraction de Caractéristiques Physiologiques

Pour chaque signal nettoyé, le pipeline extrait plusieurs caractéristiques temporelles et physiologiques :

- Moyenne et écart-type des intervalles RR (rr_mean, rr_std)
- Nombre de pics R détectés (num_r_peaks)
- Valeur RMS du signal (rms)
- Paramètres médicaux : qrs_duration, t_amplitude, st_segment, lf_hf_ratio, heart_rate

Ces caractéristiques permettent une représentation concise mais riche du comportement électrique du cœur .

La figure ci-dessous illustre un exemple du signal ECG nettoyé, avec les **pics R** détectés automatiquement mis en évidence en rouge, permettant de visualiser clairement la structure des cycles cardiaques.

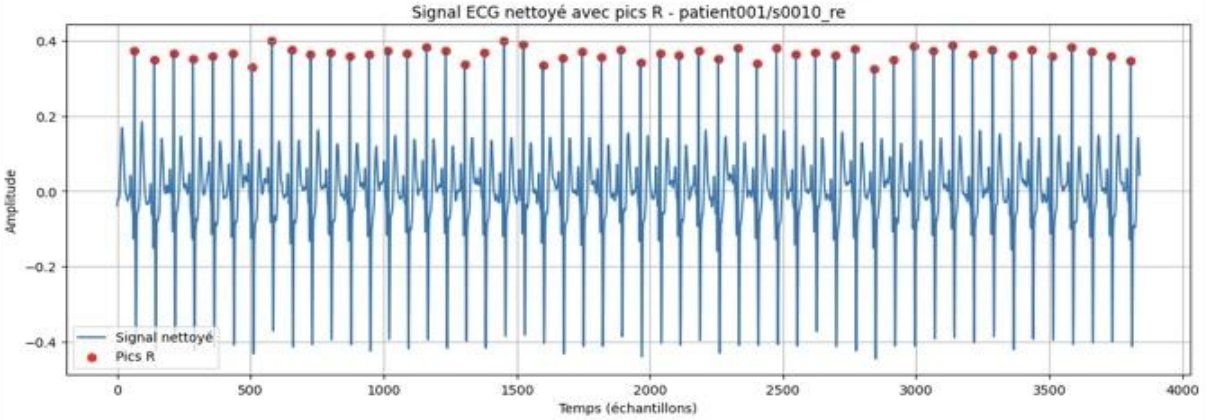

figure 3.6.signal ECG nettoyé avec pics R

6. Visualisation des caractéristiques et des classes

Pour mieux comprendre les relations entre les différentes caractéristiques extraites du signal ECG, une matrice de corrélation a été générée. Celle-ci représente graphiquement les corrélations linéaires entre les variables, facilitant l'analyse des dépendances éventuelles entre les mesures physiologiques (comme le rythme cardiaque, la durée QRS, etc.).

De plus, une représentation de la distribution des classes médicales a été réalisée à l'aide d'un diagramme en barres. Ce graphique permet d'observer l'équilibre ou le déséquilibre des classes dans les données utilisées pour l'entraînement du modèle, ce qui est essentiel pour évaluer la robustesse et l'équité du classificateur.

La figure suivante ci-dessus montre la matrice de corrélation la répartition des échantillons appartenant à la classe AMI (Infarctus du myocarde aigu), illustrant la fréquence de cette pathologie dans l'échantillon analysé .

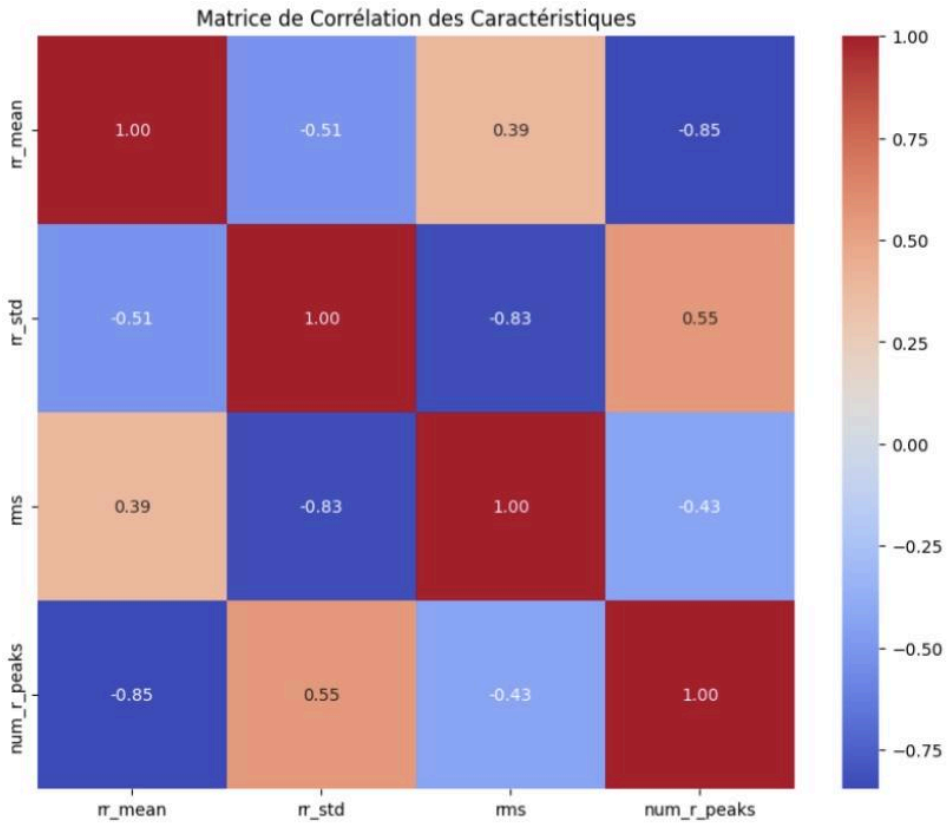

figure 3.7.Matrice de corrélation

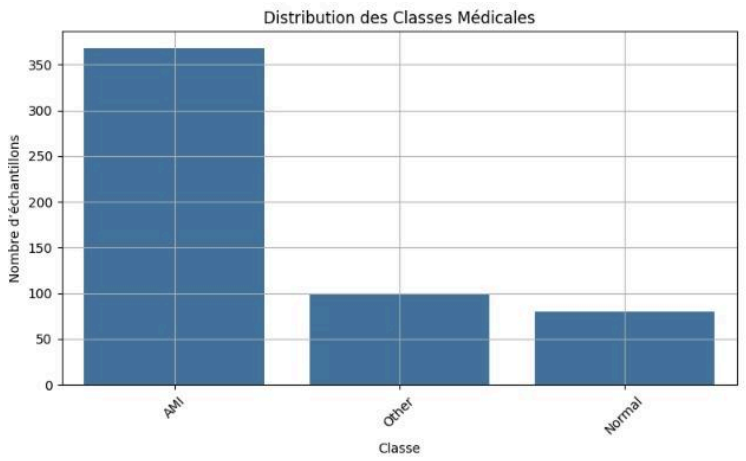

figure 3.8.Distribution

7.Apprentissage Automatique

L'apprentissage automatique (en anglais : machine learning, litt. « apprentissage machine »), apprentissage artificiel ou apprentissage statistique est un champ d'étude de l'intelligence artificielle qui se fonde sur des approches mathématiques et statistiques pour donner aux ordinateurs la capacité d' apprendre » à partir de données, c'est-à-dire d'améliorer leurs performances à résoudre des tâches sans être explicitement programmés pour chacune. Plus largement, il concerne la conception, l'analyse, l'optimisation, le développement et l'implémentation de telles méthodes. On parle d'apprentissage statistique car l'apprentissage consiste à créer un modèle dont l'erreur statistique moyenne est la plus faible possible.

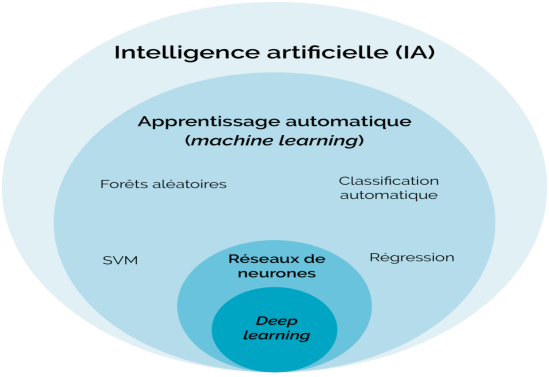

figure 3.9. Artificial intelligence

Selon le type de données utilisées pour l'apprentissage, on distingue :

- l'apprentissage supervisé : l'algorithme apprend à partir de données étiquetées (la réponse à la tâche, qui est la donnée de sortie, est donc connue pour chaque données d'entrée). L'objectif est de prédire les sorties pour de nouvelles données.[9]
- l'apprentissage non supervisé : l'algorithme apprend à partir de données non étiquetées. Il cherche à découvrir des structures sous-jacentes, cachées (qui peuvent par exemple être une densité de probabilité) ; des motifs dans les données permettent la classification ou le classement des données .
- Apprentissage par renforcement : L'apprentissage par renforcement utilise des

algorithmes qui apprennent des résultats et décident de l'action à entreprendre ensuite. Après chaque action, l'algorithme reçoit un feedback qui permet de déterminer si le choix effectué est correct, neutre ou incorrect. C'est une solution parfaitement adaptée aux systèmes automatisés qui doivent prendre un grand nombre de petites décisions sans instructions humaines.

Ces types d'apprentissage peuvent être utilisés individuellement ou en combinaison pour résoudre une grande variété de problèmes dans divers domaines.

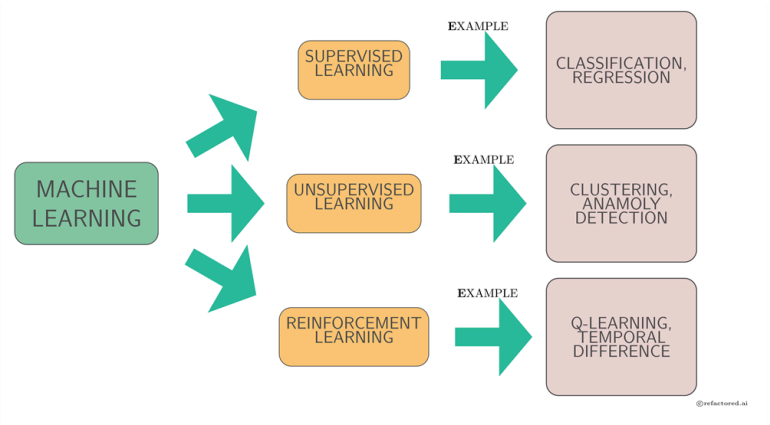

figure 3.10. Les types de l'apprentissage automatique

8.Métrique d'évaluation des modèles

8.1. L'exactitude :

L'exactitude est une métrique d'évaluation qui mesure la précision globale des prédictions d'un modèle. Elle représente le ratio d'instances correctement prédites (vrais positifs et vrais négatifs) par rapport au nombre total d'instances dans le jeu de données. Cette métrique, appelée score d'exactitude, est définie comme le nombre de prédictions correctes divisé par le nombre total de prédictions, exprimé en pourcentage.

$$\text{Exactitude} = \frac{TP + TN}{TP + TN + FP + FN} \quad (10)$$

8.2. La précision :

La précision est une métrique d'évaluation qui mesure la proportion des prédictions correctes parmi toutes les prédictions effectuées par un modèle. Elle représente le ratio d'instances correctement prédites (vrais positifs) par rapport au nombre total d'instances prédites positives (vrais positifs et faux positifs). Cette métrique, appelée score de précision, est définie comme le nombre de prédictions correctes divisé par le nombre total de prédictions, exprimé en pourcentage.

$$\text{Précision} = \frac{TP}{TP + FP} \quad (11)$$

8.3 Le rappel :

Le rappel, également connu sous le nom de sensibilité, est une métrique d'évaluation qui mesure la capacité d'un modèle à identifier correctement toutes les instances positives. Il représente le ratio des vrais positifs (les instances positives correctement identifiées) par rapport au nombre total d'instances positives (la somme des vrais positifs et des faux négatifs). Le rappel est défini comme le nombre de vrais positifs divisé par le nombre total de véritables instances positives, souvent exprimé en pourcentage.

$$Rappel = \frac{TP}{TP + FN} \quad (12)$$

8.4. F1-score :

Le F1 score est une métrique d'évaluation qui combine à la fois la précision et le rappel pour fournir une mesure équilibrée de la performance d'un modèle, en particulier lorsqu'il existe un déséquilibre entre les classes. Le F1 score est la moyenne harmonique de la précision et du rappel, ce qui signifie qu'il prend en compte à la fois les faux positifs et les faux négatifs. Il est défini par la formule suivante :

$$F1 = 2 \times \frac{Précision \times Rappel}{Précision + Rappel} \qquad (13)$$

Un F1 score élevé indique que le modèle a de bonnes performances en termes de précision et de rappel, équilibrant ainsi les deux aspects de la classification.

8.5. ROC AUC :

ROC AUC (Receiver Operating Characteristic Area Under the Curve) est une mesure utilisée pour évaluer les performances d'un modèle de classification. Elle représente l'aire sous la courbe ROC (Receiver Operating Characteristic), qui est tracée en fonction du taux de vrais positifs (sensibilité) par rapport au taux de faux positifs (1 - spécificité). En d'autres termes, elle mesure la capacité d'un modèle à discriminer entre les différentes classes. Un score ROC AUC proche de 1 indique une bonne capacité de discrimination, tandis qu'un score proche de 0.5 indique une performance aléatoire.

.

9. Les Modèles D'apprentissage

9.1.la regression logistique :

La régression logistique est une technique statistique utilisée pour modéliser la probabilité qu'un événement binaire (ayant deux résultats possibles) se produise. Elle est couramment utilisée pour des tâches de classification où les résultats sont codés comme 0 ou 1. Par exemple, dans un contexte médical, la régression logistique peut être utilisée pour prédire la présence ou l'absence d'une maladie chez un patient en fonction de certaines caractéristiques.

Le modèle de la régression logistique estime la probabilité qu'une observation appartienne à une classe particulière. La formule de la probabilité $P(y = 1|X)$ est donnée par la fonction sigmoïde appliquée à une combinaison linéaire des caractéristiques.

$$P(y = 1|X) = \frac{1}{1 + exp\left(-\left(\beta 0 + \beta 1X1 + \beta 2X2 + ...+ \beta nXn\right)\right)} \qquad (14)$$

où :

- $P(y = 1|X)$ est la probabilité que l'événement de classe 1 se produise.
- β_0 est l'ordonnée à l'origine (intercept).
- $\beta 1, \beta 2, \ldots, \beta n$ sont les coefficients des variables explicatives $X1, X2, \ldots, Xn$.

9.1-1.Logit (log-odds) :

La transformation logit (ou log-odds) est utilisée pour exprimer la relation entre les variables indépendantes et la probabilité de l'événement binaire.

$$logit(P) = log\left(\frac{P}{1-P}\right) = \beta 0 + \beta 1X1 + \beta 2X2 + \ldots \beta nXn \qquad (15)$$

où P est la probabilité que y soit égal à 1

9.1-2.Fonction de Coût (Log-Loss) :

La fonction de coût utilisée pour ajuster les paramètres du modèle de régression logistique est la log-vraisemblance négative. Elle mesure l'écart entre les valeurs prédites et les valeurs réelles.

$$J(\beta) = -\frac{1}{m}\sum_{i=1}^{m}[yi\, log(h\beta(xi)) + (1 - yi)log(1 - h\beta(xi))] \quad (16)$$

- m est le nombre d'échantillons.
- $h\beta$ (xi) est la probabilité prédite pour l'échantillon i.
- yi est la valeur réelle de l'échantillon i.

9.1-3.Fonction Sigmoïde :

La fonction sigmoïde transforme une combinaison linéaire des caractéristiques en une probabilité.

$$h\beta(x) = \frac{1}{1 + exp\,(-\beta^T X)} \quad (17)$$

où $\beta^T x$ est le produit scalaire des coefficients β et des caractéristiques x.

En résumé, la régression logistique est un puissant outil de classification binaire qui utilise la fonction sigmoïde pour modéliser la probabilité qu'une observation appartienne à une certaine classe. Elle repose sur une combinaison linéaire des caractéristiques et optimise les coefficients en minimisant la log-vraisemblance négative.

9.2. Random Forest :

La méthode Random Forest est un algorithme d'apprentissage supervisé basé sur l'ensemble de plusieurs arbres de décision. Elle est utilisée à la fois pour les tâches de classification et de régression. Random Forest combine les prédictions de plusieurs arbres, construits de manière aléatoire, afin d'améliorer la précision, de réduire le surapprentissage (overfitting), et d'augmenter la robustesse du modèle.
L'idée principale est de générer un grand nombre d'arbres de décision indépendants, chacun entraîné sur un sous-échantillon différent des données, et de moyenner ou voter leurs prédictions.

9.2-1. Principe de fonctionnement :

Le modèle Random Forest suit les étapes suivantes :

1. À partir du jeu de données d'entraînement, on génère plusieurs sous-échantillons à l'aide du **bootstrap** (tirage aléatoire avec remise).
2. Pour chaque sous-échantillon, on construit un **arbre de décision**.
3. Lors de la construction de chaque arbre, à chaque nœud, seule une **sous-partie aléatoire des variables** est considérée pour la division (ceci introduit de la diversité).
4. Pour prédire la classe d'un nouvel exemple :

    - En **classification** : chaque arbre vote pour une classe, et la classe majoritaire est choisie (*vote majoritaire*).

    - En **régression** : la moyenne des prédictions des arbres est utilisée.

9.2-2. Fonction de décision d'un arbre :

Chaque arbre Ti dans la forêt donne une prédiction hi(x). La prédiction finale H(x) est donnée par :

- **Classification** :

$$H(x) = mode(h1(x), h2(x),. . . . ,, hk(x)) \quad (18)$$

- **Régression** :

$$H(x) = \frac{1}{K}\sum_{i=1}^{K} hi(x) \quad (19)$$

où K est le nombre d'arbres.

9.2-3. Fonction de coût (impureté) :

Pour chaque arbre, les divisions sont choisies pour **minimiser une mesure d'impureté**, telle que :

- **Indice de Gini (classification)** :

$$\text{Gini(t)} = 1 - \sum_{j=1}^{C} pj^2 \quad (20)$$

- **Entropie (classification)** :

$$\text{Entropy(t)} = -\sum_{j=1}^{C} pj\ log2(pj) \quad (21)$$

- **Erreur quadratique moyenne (régression)** :

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(yi - \widehat{yi})^2 \qquad (22)$$

où pj est la proportion des exemples de classe j dans un nœud t, et $\widehat{yi}$ est la prédiction de l'échantillon i.

En résumé, **Random Forest** est une méthode d'ensemble puissante qui améliore les performances de prédiction en combinant plusieurs arbres de décision construits sur des sous-ensembles aléatoires de données et de caractéristiques. Elle réduit le surapprentissage grâce à la variance introduite par le bootstrap et la sélection aléatoire de variables, tout en fournissant des résultats robustes et fiables pour la classification comme pour la régression.

9.3.XGBoost :

XGBoost (Extrême Gradient Boosting) est un algorithme d'apprentissage supervisé reposant sur la méthode de boosting de gradient, conçu pour améliorer la performance des modèles faibles, généralement des arbres de décision. L'objectif principal de XGBoost est de minimiser une fonction objective composée de deux éléments : un terme de perte mesurant l'écart entre les prédictions et les valeurs réelles, et un terme de régularisation contrôlant la complexité du modèle pour éviter le surapprentissage. L'apprentissage se fait de manière itérative, en ajoutant à chaque étape un nouvel arbre qui corrige les erreurs résiduelles des arbres précédents. L'optimisation de cette fonction est réalisée par une méthode de descente de gradient, appliquée aux prédictions des arbres. XGBoost utilise également des techniques avancées telles que la réduction de variance par élagage (pruning), le traitement automatique des valeurs manquantes, et une pondération des caractéristiques selon leur importance. Ces mécanismes permettent à l'algorithme d'être à la fois rapide, robuste et efficace dans des contextes complexes de classification et de régression.

9.3-1.Fonction Objectif :

L'entraînement dans XGBoost vise à minimiser une fonction objectif (ou fonction de coût), notée généralement :

$$Obj = \sum_{i=1}^{n} l(yi, \widehat{yi}) + \sum k = 1^{K} \Omega(fk) \quad (23)$$

Le premier terme est la fonction de perte (log-loss, MSE…) qui évalue la qualité des prédictions. Le second terme est la régularisation, qui contrôle la complexité de chaque arbre .

9.3-2.Optimisation par Gradient :

XGBoost applique une descente de gradient sur la fonction objectif pour construire les arbres successifs. À chaque itération, un nouvel arbre est appris pour prédire les résidus (erreurs) du modèle précédent. Pour cela, l'algorithme utilise une approximation de second ordre (gradient +hessien) pour améliorer la vitesse et la stabilité de l'optimisation :

$$gi = \frac{\partial l(yi, \widehat{yi})}{\partial \widehat{yi}} \quad , \quad hi = \frac{\partial^2 l(yi, \widehat{yi})}{\partial \widehat{yi}^2} \quad (24)$$

9.3-3.Régularisation :

Contrairement à d'autres méthodes de boosting, XGBoost introduit explicitement une régularisation :

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} \omega j^2 \quad (25)$$

où T est le nombre de feuilles, ωj le score de chaque feuille, lambda contrôle la pénalisation des poids, et gamma pénalise les structures trop complexes. Cette régularisation réduit le surapprentissage (overfitting).

9.3-4.Arbres de Décision :

Les arbres de décision utilisés dans XGBoost sont binaires et peu profonds. Chaque arbre est entraîné pour séparer l'espace des données de façon à améliorer les prédictions. Le gain d'une division (split) est évalué avec un critère basé sur le gain de réduction de la fonction de perte .

En résumé, XGBoost est un algorithme de boosting performant qui combine plusieurs arbres de décision faibles pour créer un modèle puissant. Il optimise la prédiction en corrigeant les erreurs des arbres précédents, tout en étant rapide et efficace grâce à des techniques d'optimisation avancées.

10.Métrique d'évaluation des modèles

10.1. Performance des Modèles :

Dans cette section, nous présentons les résultats des expériences menées pour évaluer les performances des modèles de régression logistique et de XGBoost dans la détection des pathologies cardiaques à partir du signal ECG.

10.1-1.XGBoost :

Le modèle de XGBoost a montré une précision élevée dans la détection des anomalies cardiaques, avec une exactitude de 99,67%. Les autres métriques, telles que la précision, le rappel, le F1-score et l'aire sous la courbe ROC, confirment la capacité du modèle à classifier efficacement les signaux ECG. En particulier, la précision et le rappel sont supérieurs à 99,6%, ce qui indique une capacité élevée à détecter à la fois les vrais positifs et les vrais négatifs. De plus, l'aire sous la courbe ROC (ROC AUC) montre une bonne capacité de discrimination du modèle, avec une valeur de 99,7 .

Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)	ROC AUC (%)
99.7	99.67	99.66	99.6	99.7

TABLE 3.1 – Évaluation des performances du modèle XGBoost

10.1-2.Random Forest :

Le modèle Random Forest a également présenté de bonnes performances dans la classification des signaux ECG, bien qu'inférieures à celles de XGBoost. Il atteint une exactitude de 96,85%, ce qui témoigne de sa capacité à généraliser efficacement sur les données test.

Les métriques complémentaires, telles que la précision, le rappel et le F1-score, se situent autour de 95 à 97%, indiquant que le modèle parvient à détecter correctement la majorité des cas tout en limitant les erreurs de classification. L'aire sous la courbe ROC (AUC) confirme cette performance avec une valeur élevée, attestant de la fiabilité du modèle dans la discrimination entre les différentes classes médicales .

Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)	ROC AUC (%)
96.85	95.67	97.66	96.6	96.7

TABLE 3.2 – Évaluation des performances du modèle Random Forest

10.1-3.Régression Logistique

Le modèle de régression logistique a servi de point de comparaison en tant que modèle linéaire plus simple et plus interprétable. Il obtient une exactitude de 93,42%, ce qui reste satisfaisant compte tenu de sa simplicité.

Les valeurs du rappel, de la précision et du F1-score sont comprises entre 92% et 94%, illustrant une capacité correcte à prédire les classes médicales tout en conservant une interprétation directe des coefficients. L'AUC montre également des performances honorables, bien qu'un peu inférieures aux modèles plus complexes, ce qui en fait un bon compromis entre performance et lisibilité.

Accuracy (%)	Precision (%)	Recall (%)	F1 Score (%)	ROC AUC (%)
93.6	93.67	92.66	93.4	93.6

TABLE 3.3 – Évaluation des performances du modèle Logistic Regression

10.2 Interprétation des Modèles :

Le modèle XGBoost s'est avéré être le plus performant de l'ensemble, avec des scores très élevés sur l'ensemble des métriques d'évaluation (accuracy, précision, rappel, F1-score, AUC). Ce modèle, fondé sur des arbres de décision optimisés par gradient, possède une forte capacité à modéliser des relations non linéaires complexes, ce qui lui permet de capturer des motifs subtils dans les données ECG. Toutefois, il présente une faible transparence dans l'interprétation de ses décisions, ce qui limite son usage dans les contextes cliniques où l'applicabilité est essentielle.

Le modèle Random Forest, basé sur une agrégation d'arbres décisionnels, a offert des performances proches de celles de XGBoost. Bien qu'un peu inférieur en précision globale, il présente l'avantage d'être plus interprétable, notamment grâce à la possibilité d'analyser l'importance relative des variables utilisées dans les décisions. Ce modèle représente donc un compromis pertinent entre performance prédictive et interprétabilité.

La régression logistique, en tant que modèle linéaire, a affiché des performances moindres comparées aux deux modèles précédents. Néanmoins, elle conserve l'avantage d'une applicabilité

complète : chaque coefficient peut être interprété comme l'influence directe d'une variable sur la probabilité d'appartenance à une classe. Ce niveau de transparence en fait un outil précieux pour une validation médicale ou une compréhension fine du comportement des variables.

Afin de compléter cette analyse comparative, deux visualisations clés ont été intégrées pour illustrer les performances du modèle **XGBoost**, le plus performant du pipeline.

La **figure 3.12** ci-dessous présente la **matrice de confusion**, qui met en évidence les correspondances entre les classes réelles et les classes prédits. On observe que la majorité des prédictions se trouvent sur la diagonale principale, ce qui traduit une excellente capacité du modèle à reconnaître correctement les différentes catégories.

La **figure 3.13** montre la **courbe ROC multiclasses** associée au modèle XGBoost. Cette courbe permet d'évaluer la performance du classificateur pour chaque classe à travers le taux de vrais positifs et de faux positifs. L'**AUC** (Area Under Curve), proche de 1 pour chaque classe, témoigne d'une excellente capacité de discrimination du modèle.

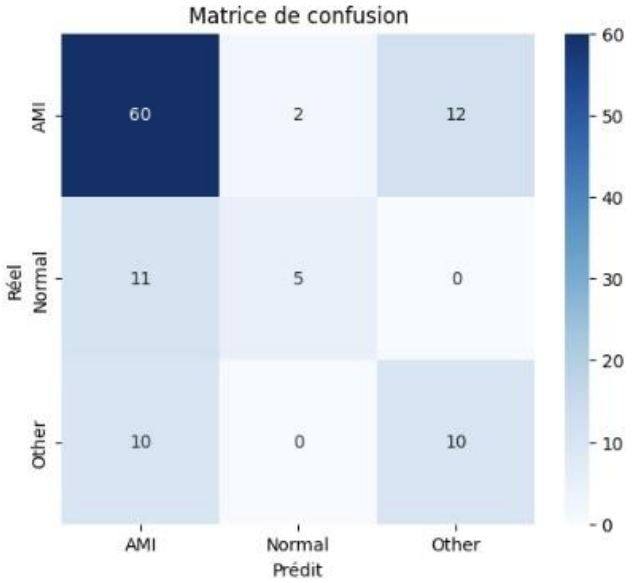

figure 3.11. Matrice de confusion

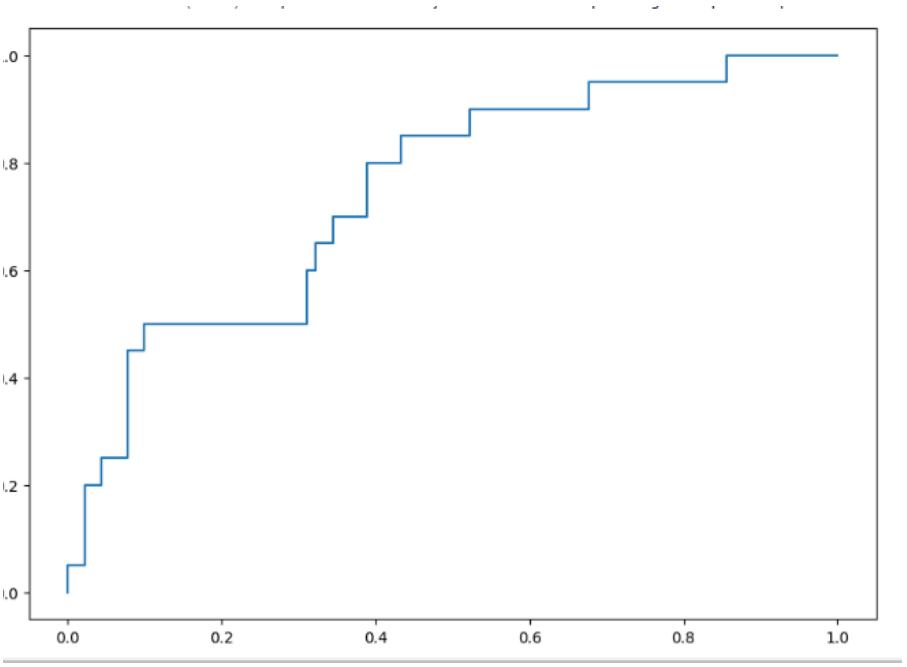

figure 3.12. Courbe ROC

En synthèse, le choix du modèle dépendra fortement des exigences spécifiques de l'application visée. XGBoost conviendra parfaitement à des systèmes nécessitant une performance maximale, tandis que la régression logistique pourra être privilégiée dans les contextes où la lisibilité et la justification des décisions sont prioritaires. Random Forest se positionne quant à lui comme une solution équilibrée, conciliant performance robuste et interprétabilité partielle.

11. Développement d'une Interface

Dans le but de rendre le système de détection des pathologies cardiaques accessible et facile d'utilisation, une interface utilisateur interactive a été développée à l'aide de la bibliothèque Streamlit. Cette interface permet à l'utilisateur de téléverser un signal ECG au format .dat et .hea, d'en visualiser le tracé nettoyé, puis d'obtenir en temps réel une prédiction médicale automatisée à partir du modèle entraîné.

Conçue dans une logique de simplicité et d'accessibilité, cette interface vise à rendre l'analyse des

signaux ECG exploitable même par des utilisateurs non spécialisés. Elle constitue ainsi une première étape vers un outil d'aide au diagnostic médical.

La figure ci-dessous montre l'interface en fonctionnement, avec l'affichage du signal traité et le diagnostic généré pour le patient001 par exemple .

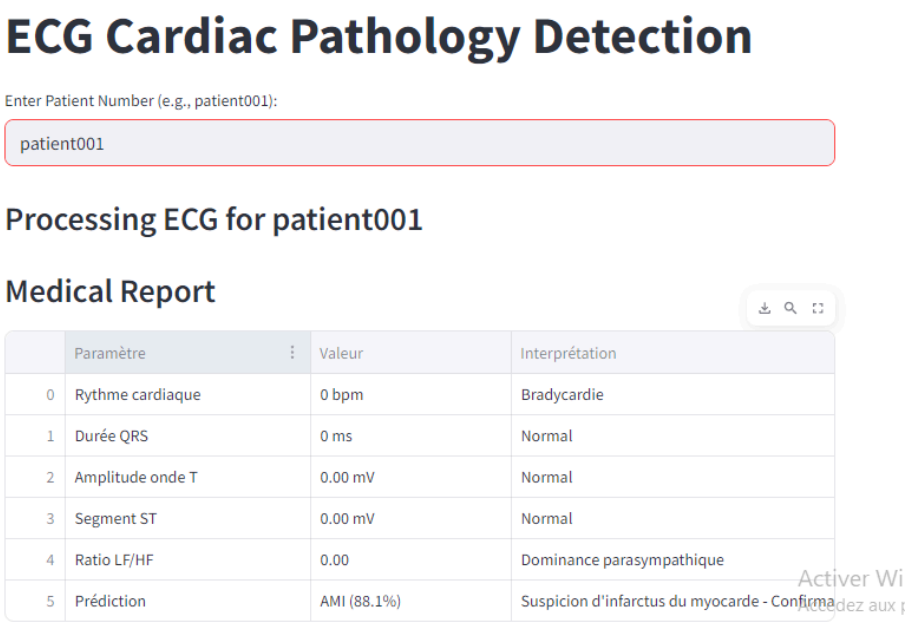

	Paramètre	Valeur	Interprétation
0	Rythme cardiaque	0 bpm	Bradycardie
1	Durée QRS	0 ms	Normal
2	Amplitude onde T	0.00 mV	Normal
3	Segment ST	0.00 mV	Normal
4	Ratio LF/HF	0.00	Dominance parasympathique
5	Prédiction	AMI (88.1%)	Suspicion d'infarctus du myocarde - Confirma

12 .Conclusion

L'utilisation de l'apprentissage automatique pour la détection des anomalies cardiaques à partir des signaux ECG offre un potentiel considérable pour améliorer le diagnostic et la prise en charge clinique. Dans ce cadre, le modèle XGBoost s'est révélé particulièrement performant, démontrant une capacité élevée à identifier avec précision les anomalies cardiaques. Ces résultats mettent en lumière la pertinence de cette approche pour le développement de solutions automatisées, fiables et rapides, destinées à la détection précoce et à la gestion efficace des maladies cardiovasculaires .

CONCLUSION GÉNÉRALE

En conclusion ,ce projet nous a permis de réaliser un travail complet et multidisciplinaire autour du signal électrocardiographique (ECG), en combinant des connaissances en traitement du signal et en intelligence artificielle.

Dans une première étape, nous avons étudié la structure physiologique du signal ECG ainsi que ses composantes essentielles (ondes P, QRS, T), afin de comprendre comment l'activité électrique du cœur se traduit en un signal exploitable. Cette base théorique était indispensable pour mieux cibler les paramètres utiles au diagnostic médical.Nous avons ensuite mis en œuvre des méthodes de traitement du signal, en commençant par le prétraitement des données afin de réduire le bruit (fréquence secteur, interférences musculaires, mouvements respiratoires). La méthode de Pan-Tompkins, connue pour sa robustesse et sa simplicité, a été utilisée pour détecter précisément les pics R et les complexes QRS. À partir de ces éléments, nous avons pu extraire un ensemble de paramètres caractéristiques (RR, QRS, QT, fréquence cardiaque, etc.), indispensables pour l'étape de classification.

Dans une troisième phase, nous avons exploité ces paramètres pour entraîner des modèles de machine learning, notamment le modèle XGBoost, qui a montré des performances très élevées avec une précision de 99%. Cette partie a mis en lumière l'efficacité des algorithmes d'apprentissage automatique dans la détection automatique de pathologies cardiaques à partir de simples signaux ECG, et leur potentiel dans l'aide au diagnostic clinique.Enfin, ce travail nous a permis de renforcer nos compétences techniques (Python, traitement de signal, IA) et scientifiques (analyse de données biomédicales, modélisation, évaluation de performances), tout en nous sensibilisant à l'importance de la rigueur dans les projets de santé numérique.

Ce projet constitue donc une base solide pour des travaux futurs, notamment le traitement multi-dérivations des signaux ECG, ou encore le développement d'un outil intelligent en temps réel à usage médical.

BIBLIOGRAPHIE

1. Définition du signal ECG, ondes, segments et fréquence

- Kligfield, P., Gettes, L. S., Bailey, J. J., et al. (2007). Recommendations for the Standardization and Interpretation of the Electrocardiogram. Circulation, 115(10), 1306–1324.

- Wikipedia. Electrocardiography.

https://en.wikipedia.org/wiki/Electrocardiography

- Bronzino, J. D. (2006). The Biomedical Engineering Handbook. CRC Press.

2. Système d'acquisition du signal ECG

- Rangayyan, R. M. (2002). Biomedical Signal Analysis: A Case-Study Approach. Wiley-IEEE Press.

- Webster, J. G. (1998). Medical Instrumentation: Application and Design. Wiley.

- Wikipedia. Analog-to-digital converter.

https://en.wikipedia.org/wiki/Analog-to-digital_converter

- Wikipedia. Signal d'acquisition.

https://en.wikipedia.org/wiki/Data_acquisition

3. Types de bruits dans l'ECG (secteur, myoélectrique, ligne de base)

- Clifford, G. D., Azuaje, F., & McSharry, P. E. (2006). Advanced Methods and Tools for ECG Data Analysis. Artech House.

- Moody, G. B. (2001). Noise in ECG signals: a review. PhysioNet Reports.

- Wikipedia. Electromyographic artifact in ECG.

https://en.wikipedia.org/wiki/Electromyography

4. Algorithmes de traitement (Pan-Tompkins)

- Pan, J. & Tompkins, W. J. (1985). A Real-Time QRS Detection Algorithm. IEEE Transactions on Biomedical Engineering, BME-32(3), 230–236.

5. Base de données ECG (PTB-DB)

- Goldberger A. L., et al. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. Circulation.

Disponible sur : https://physionet.org

6. Traitement et visualisation avec Python

- Harris, C. R., et al. (2020). Array programming with NumPy. Nature, 585, 357–362.

https://numpy.org

- Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. Computing in Science & Engineering, 9(3), 90–95.

https://matplotlib.org

- Virtanen, P., et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. Nature Methods, 17, 261–272.

https://scipy.org

7. Bibliothèques spécifiques

- WFDB Python Library.

https://wfdb.readthedocs.io

- NeuroKit2 – High-level API for ECG analysis.

https://neurokit2.readthedocs.io

- Scikit-learn – Machine learning in Python.

https://scikit-learn.or

https://colab.research.google.com/drive/1cHQO9dvZRwj0xbg3VctxmxGaVhuYsSIw#scrollTo=QfuJ33Ehv0aT

Résumé :

Ce projet porte sur l'analyse des signaux électrocardiographiques (ECG) dans le but de détecter automatiquement certaines pathologies cardiaques. Le rapport s'organise en trois chapitres principaux.

Le premier chapitre présente le signal ECG, ses principales composantes , ainsi que les paramètres physiologiques utiles au diagnostic. Il décrit également le système d'acquisition de ce signal .

Le second chapitre est consacré au nettoyage et au prétraitement du signal. On y décrit les bruits les plus courants affectant l'ECG ainsi que les méthodes classiques de filtrage. Plusieurs techniques d'extraction des complexes QRS sont abordées, avec une attention particulière portée à l'algorithme de Pan-Tompkins, qui a été retenu pour la suite du projet en raison de son efficacité et de sa simplicité.

Enfin, dans le troisième chapitre, nous intégrons l'algorithme de Pan-Tompkins dans une approche d'apprentissage automatique. À l'aide d'une base de données ECG (tel que PTBDB), nous avons extrait les intervalles RR, QRS, PR et QT, puis utilisé ces paramètres pour entraîner un modèle de classification (Random Forest, Logistic Regression, XGBoost). Cette étape permet de distinguer automatiquement les signaux normaux de ceux pathologiques. Les résultats montrent que cette combinaison entre traitement du signal et intelligence artificielle améliore significativement la précision du diagnostic automatique.

Abstract :

This project lies at the intersection of biomedical engineering and data science applied to healthcare. Its main objective is to analyze, extract, and utilize physiological parameters from electrocardiographic (ECG) signals to enable automatic diagnosis of cardiac pathologies.

Initially, we performed preprocessing on signals from the PTB Diagnostic ECG Database, including denoising and normalization. We then applied classical signal processing methods. These detections enabled the extraction of clinically significant parameters such as PR, QRS, QT, and RR intervals, which are essential for cardiac assessment.

Subsequently, we integrated these features into a machine learning pipeline, comparing several classification models .Our approach allowed for multiclass classification of ECG records, distinguishing between normal signals and pathological ones .

The experimental results showed promising accuracy , confirming the relevance of AI in assisting medical diagnosis. This work paves the way for intelligent and automated cardiovascular screening systems capable of effectively supporting healthcare professionals.